

Data Mining & Machine Learning
2025-2026

“Fatores explicativos do preço dos imóveis residenciais em Portugal”

Afonso Bragança Gonçalves Azenha nº2025121150

Inês Almeida Gonçalves nº2025120588

Pedro Miguel Soares nº2025112569

Sara Henriques Simões nº2025103116



1. Entendimento do negócio

Entendimento do negócio

01 *Objetivo:* Influência de fatores estruturais e geográficos no preço final dos imóveis

02 *Abordagem:* Substituir a subjetividade tradicional por Modelos de Regressão Hedónica

03 *Questão-Chave:* Contribuição de cada característica para determinar o preço

04 *Meta:* Capacidade explicativa mínima de 50%





2. Compreensão dos dados



Compreensão dos dados

Amostra: Quase 37.000 registos consolidados (apartamentos e moradias)

Distribuição: Foco nos centros urbanos do Porto (~7.000) e Lisboa (~6.000)

Variáveis: Preço (Target), Área, Localização e Tipologia.

Qualidade: Desafios com dados não padronizados, erros de codificação e outliers extremos.

The background of the slide is a photograph of a row of colorful terraced houses, likely in a European city. The houses are painted in various colors including light blue, white, yellow, and red. They have multiple windows with white frames and some have small balconies with metal railings. The image is slightly blurred and has a soft, warm tone. A semi-transparent white rounded rectangle is overlaid on the image, containing the title text.

3. Preparação dos dados



Seleção dos dados

Etapas:

- Definição de Objetivos
- Relevância das Variáveis
- Seleção de Registos
- Amostragem e Separação

Variáveis incluídas:

- Type
 - Location
 - Property
 - Area
-

Limpeza dos Dados

01 Uniformização das variáveis *Area* e *Price*, relativamente ao ponto

02 Limpeza e Uniformização da variável *Location*

03 Tratamento de outliers na variável *Price*



04 Filtro de Limpeza na variável *Area*






Construção dos Dados

- Aplicação da transformação logarítmica
- Uniformização do atributo *Type*
- Codificação através de *One-Hot Encoding* das variáveis *Location* e *Property*




4. Modelação

Abordagem à Modelação



Regressão Linear Múltipla



Árvore de Decisão

Metodologia de Teste

Divisão dos Dados:

Treino: 80%

Teste: 20%

Reprodutibilidade:

random_state = 42

Otimização:

GridSearchCV com Cross-Validation (k=5)



Modelo 1: Regressão Linear Múltipla

Regressão Linear Global

R^2 : 0,7892
MAE: 77.903,98€

Regressão Linear por Localização


Setúbal: $R^2=0.53$
Braga: $R^2=0.52$

Lisboa: $R^2=0.21$
Porto: $R^2=0.34$

Distrito	R2	MAE (€)	Amostra (n)
Setúbal	0.53	102.295,89	2678
Braga	0.52	86.437,06	2009
Bragança	0.46	72.920,46	243
Santarém	0.43	106.330,18	1447
Castelo Branco	0.43	91.585,85	890
Porto	0.34	125.226,94	6524
Évora	0.32	163.318,92	567
Faro	0.31	147.085,47	2845
Viana do Castelo	0.28	110.126,11	1609
Ilha da Madeira	0.26	140.267,60	327
Portalegre	0.26	130.908,17	602
Viseu	0.22	135.030,46	583
Aveiro	0.22	125.204,69	2201
Leiria	0.21	165.963,40	1674
Lisboa	0.21	194.852,05	4435
Coimbra	0.20	118.765,75	1619
Guarda	0.19	97.699,19	387
Beja	0.18	180.637,15	642
Vila Real	0.15	139.446,33	514

Modelo 2: Ávore de Decisão

Ávore Otimizada (Profundidade Real: 7 - R^2 : 0.44)



5. Avaliação

Avaliação de resultados e desempenho preditivo

Comparação entre Regressão Linear e Árvore de Decisão

A Regressão Linear apresenta:

- MAE mais baixo → maior precisão média.
- Melhor desempenho no mercado habitacional standard.

A Árvore de Decisão:

- Maior erro médio e sensibilidade a outliers
- Maior capacidade de segmentação do mercado

Métrica	Regressão Linear	Árvore de Decisão
R ² (Qualidade)	78,92%	44,20%
MAE (Erro Médio)	77.903,98 €	197.739,50 €
RMSE (Robustez)	109.455,19 €	425.299,32 €

Diagnóstico de erros e impacto de outliers


Relação entre valores reais e previstos no modelo de Árvore de Decisão.

Boa precisão para imóveis de baixo e médio valor.

Forte dispersão nos imóveis de valor elevado.

Presença clara de outliers extremos.

Indício de heterocedasticidade.



Relevância das variáveis e regras de decisão


Área como principal fator explicativo (~62%)

Forte peso da localização em Lisboa e Porto

Tipologia e restantes localizações com menor impacto

Confirma-se:

- Assimetria regional do mercado imobiliário
- Concentração de valor nos grandes centros urbanos



Fiabilidade por segmento e revisão do processo

Fiabilidade por segmento

- Elevada fiabilidade no mercado habitacional standard
- Baixa fiabilidade no segmento de luxo
- Sensibilidade elevada a imóveis de grande área em zonas premium

Revisão do processo

- Objetivo do projeto cumprido
- Preparação dos dados foi a fase mais crítica
- Transformações logarítmicas decisivas para o desempenho

Próximos passos

- Inclusão de variáveis qualitativas
- Segmentação do mercado em sub-modelos
- Teste de modelos não-lineares avançados





OBRIGAD@!