



**Coimbra
Business School**

Politécnico de Coimbra

Unidade Curricular de Data Mining & Machine Learning

Mestrado em Análise de Dados e Sistemas de Apoio à Decisão

Ano Letivo 2025-2026



“Fatores explicativos do preço dos imóveis residenciais em Portugal”

Estudo Elaborado a 4 de janeiro de 2026

Autores:

Afonso Bragança Gonçalves Azenha nº: a2025121150

Inês Almeida Gonçalves nº: a2025120588

Pedro Miguel Soares nº: a2025112569

Sara Henriques Simões nº: a2025103116

Índice

Índice de Figuras	iii
Índice de Tabelas.....	iv
Índice de Gráficos	v
Lista de siglas e acrónimos	vi
Introdução.....	1
1. Entendimento do negócio.....	2
1.1. Determinar os objetivos do tema	2
1.2. Avaliação da situação atual	3
1.3. Definição dos objetivos do Data Mining	5
1.4. Elaborar o plano do projeto.....	6
2. Compreensão dos dados	8
2.1. Recolha e Estrutura dos Dados Iniciais	8
2.2. Descrição dos dados	10
2.3. Exploração dos dados	11
2.4. Análise da qualidade dos Dados	15
3. Preparação dos dados	17
3.1. Seleção dos dados	17
3.2. Limpeza dos Dados.....	18
3.3. Construção dos dados.....	20
3.4. Integração dos dados	22
3.5. Formatação dos dados	23
4. Modelação	23
4.1. Seleção das técnicas de modelação.....	24
4.2. Geração do desenho de testes.....	26
4.3. Implementação e Resultados: Regressão Linear.....	27
4.3.1. Regressão Linear Global.....	27
4.3.2. Regressão Linear por Localização	28
4.4. Implementação e Resultados: Árvore de Decisão	30
4.4.1. Interpretação da Estrutura da Árvore	31
4.5. Análise Comparativa de Desempenho.....	32
5. Avaliação	33
5.1. Avaliação de resultados.....	33
5.1.1. Análise comparativa de desempenho preditivo	33
5.1.2. Diagnóstico de erros e impacto de outliers.....	34

5.1.3. Validação das regras de decisão e relevância das variáveis	36
5.1.4. Diagnóstico de fiabilidade por segmento de mercado	37
5.2. Revisão do processo	38
5.3. Determinar os próximos passos	38
Anexos.....	42
Referências:.....	46

Índice de Figuras

Figura 1 - Fases do modelo de referência CRISP-DM (Fonte: Chapman et al, 2000)	1
Figura 2 - Tarefas da fase Modelação.....	24
Figura 3 - Tarefas da fase Modelação.....	24

Índice de Tabelas

Tabela 1 - Classificação de atributos	11
Tabela 2 - Desempenho da Regressão Linear por Localização	28
Tabela 3 - Comparação de métricas entre os modelos preditivos	33
Tabela 4 - Matriz de confiabilidade final	37

Índice de Gráficos

Gráfico 1 - Composição da base de dados por categoria de imóvel.....	9
Gráfico 2 - Frequência de todas as Tipologias da base de dados	11
Gráfico 3 - Frequência das 10 Tipologias mais frequentes da base de dados.....	12
Gráfico 4 - Frequência da Localização dos imóveis	13
Gráfico 5 - Frequência da Área dos imóveis	14
Gráfico 6 - Frequência de Preços dos imóveis	15
Gráfico 7 - Relação entre o Preço e a Área dos imóveis	16
Gráfico 8 - Frequência da localização dos imóveis (dados limpos)	19
Gráfico 9 - Distribuição Normalizada da variável Price e Area	20
Gráfico 10 - Frequência das tipologias (dados limpos).....	21
Gráfico 11 - Comparação entre o erro médio absoluto e a raiz do erro quadrático médio ...	35
Gráfico 12 - Dispersão entre valores reais e previstos no modelo de Árvore de Decisão....	35
Gráfico 13 - Hierarquia de importância das variáveis no modelo de árvore de decisão.....	36

Lista de siglas e acrónimos

AED: Análise Exploratória de Dados

APIs: Interfaces de Programação de Aplicações

AVMs: Automated Valuation Models

CRISP-DM: *Cross-Industry Standard Process for Data Mining*

CSV: *Comma-Separated Values*

MAE: Mean Absolute Error

POI: Pontos de interesses

RMSE: *Root Mean Squared Error*

Introdução

O presente projeto foi desenvolvido no âmbito da unidade curricular de Data Mining & Machine Learning do mestrado em Análise de Dados e Sistemas de Apoio à Decisão do Instituto Superior de Contabilidade e Administração de Coimbra.

O relatório está organizado consoante a metodologia padrão CRISP-DM (*Cross-Industry Standard Process for Data Mining*), apresentada na Figura 1. Esta metodologia contém diversas fases no decorrer do projeto de mineração de dados (Belfo, 2020) e (Chapman et al, 2000).




Figura 1 - Fases do modelo de referência CRISP-DM (Fonte: Chapman et al, 2000)

As áreas em estudo neste trabalho são o Mercado Imobiliário e a Avaliação de Propriedades em Portugal. O principal objetivo é analisar a relação entre as características estruturais dos imóveis, nomeadamente a sua tipologia, o tipo de habitação e a área e o preço de mercado. Pretende-se identificar padrões e os diversos fatores preditivos que influenciam o valor da venda dos imóveis, possibilitando uma melhor compreensão do mercado imobiliário português.

Os dados analisados são provenientes de duas bases de dados do *Kaggle*, representando um conjunto robusto de registos de apartamentos e casas, após consolidados num único *dataset*. A sua seleção deveu-se à sua qualidade e abrangência, e sobretudo capacidade de extrair resultados significativos que apoiem

os objetivos da pesquisa. Todas as variáveis serão alvo de análise estatística e posteriormente apresenta-se os resultados objetivos.

O desenvolvimento do projeto seguirá as fases do CRISP-DM, iniciando-se pelo entendimento do negócio e a exploração dos dados, seguindo-se uma descrição onde se aborda a preparação dos dados realizada e respetiva transformação. Por fim, será realizada a modelação, onde serão aplicadas técnicas de *Machine Learning* para construir o modelo preditivo, e concluir-se-á com a avaliação do modelo construído.

1. Entendimento do negócio

A fase de compreensão do negócio é a primeira etapa do modelo CRISP-DM, a mesma tem como objetivo principal a tradução do problema de negócio e a implementação de objetivos da área de estudo em metas concretas de *Data Mining*.

1.1. Determinar os objetivos do tema

Inicialmente o estudo foca-se no entendimento profundo das necessidades do mercado imobiliário residencial em Portugal. Este mercado demonstra uma elevada complexidade e diversas oscilações, onde os métodos de avaliação tradicionais revelam-se limitados visto serem influenciados pela subjetividade e incapacidade de isolar o peso de cada variável (Shiller, 2015). Estas dificuldades geram falhas na informação e complicam a tomada de decisões informadas.

Como forma de combater as falhas encontradas, aplicam-se técnicas avançadas de *Data Mining* e Modelos de Regressão Hedônica. Estes modelos permitem a separação e medição do impacto individual de cada variável estrutural e geográfico do imóvel no preço final da transação, os chamados fatores explicativos.

O principal objetivo deste trabalho é construir um modelo analítico capaz de quantificar a influência de cada fator explicativo individualmente no preço final da transação. Para além disso, pretende-se contribuir para a transparência e objetividade do mercado, através da aplicação de técnicas que fundamentam tecnicamente as avaliações.

De forma a resolver o problema apresentado, o projeto visa responder a questões como “Qual é a contribuição real individual de cada variável independente

na formação do preço final do imóvel?” ou “De que forma a localização geográfica atua como um fator diferenciador de valor no mercado imobiliário português?”

A fiabilidade e sucesso do projeto serão aferidos pela capacidade do modelo em explicar uma parte significativa da variação dos preços, confirmando que os fatores analisados são estatisticamente relevantes.

A expectativa é que o modelo desenvolvido permita fazer uma estimativa de preço, e revele o peso exato de cada fator na formação do valor, como é exigido nos Modelos de Avaliação Automática (AVMs). Espera-se também que o modelo, com as variáveis independentes escolhidas, consiga explicar pelo menos 50% da variável dependente.

1.2. Avaliação da situação atual

Nesta segunda etapa, procede-se à avaliação dos recursos disponíveis e à delimitação dos requisitos e restrições que moldarão o desenvolvimento do projeto. Este exame inicial é fundamental para confirmar a viabilidade da identificação dos fatores explicativos do valor de venda.

Inventário de Recursos

O projeto é realizado por uma equipa de mestrandos em Análise de Dados e Sistemas de Apoio à Decisão, nomeadamente Afonso Bragança Gonçalves Azenha, Inês Almeida Gonçalves, Pedro Miguel Soares e Sara Henriques Simões. Estes autores são responsáveis pela escolha do *dataset*, pelo estudo exploratório, pela preparação dos dados, pela modelação e, por fim, pela avaliação dos resultados e redação do relatório, com o acompanhamento do professor orientador da unidade curricular.

O *dataset* central é obtido através da plataforma *Kaggle (Portuguese Real Estate Listings Dataset)*, sendo inicialmente composto por dois ficheiros CSV (*Comma-Separated Values*) que serão integrados: um para apartamentos e outro para moradias. A escolha do *dataset* baseou-se na sua abrangência geográfica em Portugal e na diversidade das características do imóvel que atuarão como fatores explicativos.

O trabalho será elaborado recorrendo aos *computadores* pessoais dos autores. As ferramentas essenciais incluem a linguagem *Python*, indispensável para a análise de dados, limpeza, tratamento e aplicação dos algoritmos de *Machine Learning*. O *software* de apoio como o *Microsoft Excel* ou o *Google Docs* será utilizado para a organização do relatório e eventuais visualizações preliminares.

Requisitos, Pressupostos e Restrições

O desenvolvimento do estudo exige o recurso ao *dataset* do *Kaggle* e a garantia de que os dados serão devidamente limpos e preparados para a modelação. A metodologia a aplicar deve ser baseada em técnicas de *Data Mining* e *Machine Learning* focadas na regressão, sendo o resultado esperado um modelo capaz de medir o impacto das características do imóvel no seu preço de venda.

Assume-se que o *dataset* do *Kaggle*, após o devido tratamento de ruído e *outliers*, constitui uma representação fiel das ofertas do mercado imobiliário residencial em Portugal. Pressupõe-se ainda que as variáveis disponíveis (Tipologia, Área, Localização e Categoria) são suficientes e relevantes para a identificação dos fatores explicativos e a construção de um modelo com desempenho aceitável.

A principal restrição é a limitação dos dados fornecidos. O *dataset* pode estar incompleto no que respeita a variáveis que seriam ideais para uma avaliação mais precisa, tais como o ano de construção, o estado de conservação ou ainda o certificado energético. Existe também uma restrição temporal, imposta pelo calendário académico, o que significa que existem dados apenas até ao mês de novembro de 2025 e a inerente limitação de generalização dos resultados, que são limitados pela amostra do *dataset* em questão.

Riscos e contingências

Ao recorrer a um *dataset* disponível em fontes públicas e ferramentas *open-source*, tem de se ter em consideração a possível existência de erros de codificação de caracteres ou valores irrealistas (*outliers*) que podem enviesar o modelo.

Será necessário a implementação de um dicionário de mapeamento rigoroso e a aplicação de filtros de limpeza baseados concretos para eliminar as observações inválidas.

1.3. Definição dos objetivos do Data Mining

O *Data Mining* não se limita à recolha de dados, dado que a sua essência reside na capacidade de extrair conhecimento útil a partir de grandes volumes de informação, recorrendo a metodologias de análise estatística. Para este estudo, a análise será concentrada em duas vertentes principais, a Descrição e a Regressão. O objetivo é, portanto, extrair conhecimento útil através de metodologias de análise estatística, centrando-se em três metas específicas:

- **Análise de fatores explicativos:** determinar e medir a importância de cada variável de entrada na definição do valor final. A regressão deve determinar, de forma estatística, se a área, por exemplo, é um preditor mais forte do que a localização para a amostra em estudo, fornecendo uma base objetiva para a avaliação.
- **Construção do modelo de Regressão:** desenvolver um modelo matemático que, ao receber as características de um imóvel, consiga explicar o seu preço de venda e, consequentemente, estimá-lo com a margem de erro mais reduzida possível. Este modelo visa mapear as relações complexas entre os atributos do imóvel e o valor final de mercado.
- **Descrição e resumo do mercado:** proporcionar uma visão geral e simples sobre a distribuição dos preços e das características dos imóveis no mercado português. Esta vertente descritiva é essencial para enquadrar os resultados da Regressão, destacando tendências regionais e de tipologia.

O desafio central a ser resolvido é a mensuração do efeito que atributos dos imóveis exercem sobre o seu valor, um processo fundamental na área da avaliação.

Critérios de Sucesso do *Data Mining*

- **Coeficiente de Determinação (R^2):** O modelo deve apresentar uma capacidade explicativa da variabilidade dos preços de, no mínimo, 50% para que possa ser considerado estatisticamente relevante.

- **Minimização do Erro:** Cálculo de métricas de erro, nomeadamente (*Mean Absolute Error*) MAE e (*Root Mean Squared Error*) RMSE, que apresentem uma precisão preditiva elevada, de modo a garantir que a margem de erro é reduzida.
- **Estabilidade:** É necessário que o modelo revele ser robusto e uma boa capacidade de generalização, evitando fenómenos de *overfitting*.

1.4. Elaborar o plano do projeto

Para assegurar que o projeto se mantém fiel aos objetivos estabelecidos acima e que o resultado final é um modelo preditivo robusto, o trabalho segue integralmente a metodologia CRISP-DM. Esta estrutura atua como um roteiro para o desenvolvimento, garantindo que o foco principal permanece na identificação e na medição dos fatores explicativos do valor de mercado.

Plano do Projeto

1. Entendimento do negócio: Aqui, estabeleceu-se a necessidade de uma ferramenta objetiva para a avaliação imobiliária. O objetivo principal foi definido como uma tarefa de regressão sobre a variável Preço, com o intuito de identificar os fatores explicativos que influenciam esse valor, sendo a unidade de análise o imóvel residencial.
2. Compreensão dos dados: Nesta fase, essencialmente exploratória, será efetuada a recolha e unificação dos ficheiros do Kaggle. A Análise Exploratória de Dados (AED) focar-se-á em identificar os problemas de qualidade intrínsecos aos anúncios imobiliários, essenciais para determinar o tratamento necessário da base de dados, tal como a formatação de preços e áreas, a dispersão na tipologia e a necessidade de padronização da localização. Esta análise define o roteiro de limpeza.
3. Preparação dos dados: Esta é a fase de mais complexa, pois, foca-se no tratamento e padronização dos fatores explicativos. Será realizada a integração dos dois ficheiros de origem para criar a variável categoria

(Apartamento/Moradia) e a limpeza e transformação dos dados brutos como a conversão de Preço e Área para numérico, a normalização da Tipologia para um formato consistente e o tratamento de erros na Localização. O tratamento dos *outliers* será de extrema importância para garantir que os fatores explicativos modelados representam o mercado residencial típico.

4. Modelação: Será efetuada a aplicação de diferentes algoritmos (por exemplo, *Random Forest Regressor*, Regressão Linear, e *Gradient Boosting*). O objetivo é construir o modelo com maior capacidade de explicação para o Preço, determinando o peso real da Área, Tipologia e Localização no valor final.
5. Avaliação: O desempenho dos modelos será avaliado rigorosamente, utilizando métricas de erro como o RMSE (para medir a precisão da estimativa de valor) e o R^2 (para quantificar o quanto o conjunto de fatores consegue, de facto, explicar a variação dos preços).
6. Implementação (*Deployment*): Por fim, traduz-se o trabalho em conhecimento prático. Serão comunicados claramente os fatores explicativos encontrados e o seu impacto quantificado. O resultado é um relatório que pode servir como base para uma ferramenta de *valuation*, auxiliando os intervenientes do mercado a entenderem como o mercado valoriza as características específicas de um imóvel.

Pressuposto inicial das Ferramentas Técnicas

A escolha das ferramentas técnicas a utilizar baseou-se na sua capacidade de suportar diversos métodos analíticos essenciais durante o estudo. Optou-se pela Regressão (Linear Múltipla) dada a sua interpretabilidade e a Indução de Árvores de Decisão devido à sua flexibilidade em lidar com relações não-lineares entre as variáveis.

A utilização de Python, nomeadamente as bibliotecas Pandas, Matplotlib entre outras deve-se à sua robustez no pré-processamento e modelação estatística.

2. Compreensão dos dados

A fase de Compreensão dos Dados (*Data Understanding*) é a segunda etapa do modelo CRISP-DM. O objetivo central é conhecer em detalhe o *dataset* a ser estudado, nomeadamente a aquisição, descrição e análise exploratória dos dados, visando identificar a sua estrutura, qualidade e problemas inerentes, o que é um passo imprescindível para a identificação dos fatores explicativos do valor de habitações.

2.1. Recolha e Estrutura dos Dados Iniciais

Os dados utilizados neste projeto são provenientes do *Portuguese Real Estate Listings Dataset*, obtidos na plataforma *Kaggle*, sendo a fonte primária de informação sobre os anúncios imobiliários em Portugal.

A escolha deste conjunto de dados fundamentou-se, primeiramente, na elevada relevância socioeconómica do setor imobiliário em Portugal, um mercado que atravessa uma fase de grande dinamismo e volatilidade de preços, tornando a previsão de valores um desafio permanente.

Em segundo lugar, a seleção deveu-se à adequação técnica e eficiência dos atributos disponíveis. Ao concentrar-se nas variáveis mais influentes do valor imobiliário (Área, Localização e Tipologia) e excluir ruído excessivo, o *dataset* promove a criação de modelos mais robustos e generalizáveis. Esta estrutura focada evita a complexidade desnecessária (*overfitting*), potenciando uma maior precisão preditiva sobre os fatores que realmente impactam o preço final.

O conjunto de dados original está segmentado em duas fontes primárias distintas, o *portugal_apartments.csv* (para apartamentos) e *portugal_housing.csv* (predominantemente para moradias). A decisão de integrar estes dois ficheiros justifica-se pela necessidade de obter uma visão abrangente e completa do mercado residencial, formando um único conjunto de dados que representa a totalidade das ofertas analisadas e dos fatores explicativos relevantes.




Gráfico 1 - Composição da base de dados por categoria de imóvel

A análise da Figura 2 revela que o *dataset* apresenta uma distribuição equilibrada entre apartamentos e moradias, contabilizando 16.134 e 20.842 registos, respetivamente, totalizando 36.976 registos.

Este equilíbrio é um ponto forte e garante que o modelo terá um volume de observações significativo em ambas as classes de modo a aprender a quantificar o peso da variável *Property*, sem que nenhuma das classes seja dominante, assegurando a validade estatística do modelo final.

Atividades de Carregamento e Requisitos

As bases de dados foram carregadas no *notebook* criado especificamente para a realização deste estudo no *Python*, utilizando a biblioteca *Pandas* de modo a permitir o entendimento inicial da estrutura dos mesmos.

Concluiu-se que as diversas variáveis necessárias para atingir os objetivos definidos se encontravam disponíveis, embora em formatos que exigem pré-processamento.

Optou-se utilizar a totalidade dos registos disponíveis para que a significância estatística nas análises regionais e por categoria de imóvel fossem asseguradas.

2.2. Descrição dos dados

A análise exploratória inicial incidiu sobre as variáveis essenciais que irão compor o modelo preditivo, revelando de imediato problemas de formatação e consistência, típicos de dados de anúncios.

- **Preço:** É a variável de saída (*target*) do modelo, o valor que se pretende explicar e estimar. Encontra-se formatada como *string* (exemplo: 185 000,00 €), o que impede a sua utilização em qualquer análise estatística. É essencial a sua conversão para o tipo numérico (*float*) para que possa ser utilizada na Regressão.
- **Área:** Variável de entrada quantitativa, um dos principais fatores explicativos de valor. Também está em formato de texto e demonstra inconsistências de formatação, tanto na notação decimal quanto na inclusão da unidade de medida (m2).
- **Tipologia:** Variável de entrada que descreve o número de quartos, um fator explicativo essencial. Foi identificada uma alta heterogeneidade no registo, pois o *dataset* mistura formatos padronizados (exemplo: T2), descrições textuais e registos de erro grosseiro (exemplo: T60), exigindo uma normalização complexa para a modelagem.
- **Localização:** Variável de entrada que indica o distrito, um fator explicativo com forte impacto no valor de mercado dos imóveis. A exploração detetou erros de codificação de caracteres (exemplo: Set??bal), o que implica a realização da limpeza e padronização para que os efeitos geográficos sejam corretamente isolados e medidos pelo modelo.
- **Categoria:** Variável a ser construída que irá distinguir o tipo de imóvel (Apartamento ou Moradia), atuando como um fator explicativo categórico para a diferença de valor entre os segmentos.

Atributo	Tipo	Mínimo	Máximo	Média	Desvio Padrão	Observação de Negócio
Preço	Numérico	0 €	2.5B €	~489k €	Elevado	Presença de <i>outliers</i> extremos e "Preço sob consulta".
Área	Numérico	1 m²	3M m²	~160 m²	Elevado	Áreas irrealistas sugerem erros de inserção ou terrenos.
Tipologia	Categórico	0 (Studio)	60	T2/T3	N/A	Elevada heterogeneidade de formatos (T2 vs 2-Bedroom).
Localização	Categórico	N/A	N/A	N/A	N/A	Concentração em Porto e Lisboa; erros de caracteres (??).

Tabela 1 - Classificação de atributos

2.3. Exploração dos dados

Distribuição por tipologias




Gráfico 2 - Frequência de todas as Tipologias da base de dados




Gráfico 3 - Frequência das 10 Tipologias mais frequentes da base de dados

A exploração detalhada da variável Tipologia demonstra um grande desafio inerente à utilização de dados de anúncios *online*, uma vez que estes apresentam elevada heterogeneidade e falta de padronização dos seus rótulos. Nas Figuras 3 e 4 é visível que o *dataset* utiliza simultaneamente a notação técnica portuguesa (Ex: T2, T5, T15) e descrições textuais em inglês (Ex: *3-Bedroom*, *Studio*). Para além disso, o *dataset* inclui registos como T60, T26, *Penthouse* que são extremamente raros e sublinham a necessidade da limpeza desta variável, e não terão significância estatística suficiente para estimar um coeficiente de regressão fiável.

Esta inconsistência requer uma normalização de forma a converter as diversas designações utilizadas em rótulos equivalentes. Na Figura 4 ao analisar as 10 tipologias mais frequentes, esta situação destaca-se, pois, há observações que deveriam ser agrupadas, mas encontram-se separadas devido à heterogeneidade existente, como é o caso de “T3” e “3-Bedroom” ou “T4” e “4-Bedroom”. Se esta limpeza não for efetuada, o modelo de Regressão será forçado a tratar tipologias idênticas como variáveis separadas, diluindo o seu poder explicativo e introduzindo ruído.

No entanto, apesar da necessidade de efetuar a limpeza da variável, é possível observar na Figura 4 a forte concentração da oferta nas tipologias mais transacionadas, como os T2 e T3, com cerca de 10.000 observações e 12.000 observações, respetivamente.

Distribuição por localização



Gráfico 4 - Frequência da Localização dos imóveis

Durante a análise da variável Localização, constata-se que existe uma clara concentração de registos em grandes centros urbanos e distritos com mercados imobiliários mais ativos. O distrito do Porto apresenta o maior número de imóveis, com cerca de 7000 imóveis, seguido pelo distrito de Lisboa com quase 6000 registos.

No entanto, apesar desta concentração ser esperada, a Figura 5 evidencia alguns problemas de codificação de caracteres como “??”, tornando os registos inválidos para a análise direta, nomeadamente no distrito de Évora ou nas observações designadas “Apartamento para comprar”.

De referir que existem localizações com muito poucos registos (Ex: Ilha das Flores, Ilha da Terceira), representando um risco pois o modelo poderá sobre ajustar-se a poucas observações, gerando coeficientes não fiáveis.

Para além disso, existem observações localizadas no mesmo distrito que se encontram separadas em dois grupos distintos, pois o *dataset* não apresenta a devida uniformização relativamente à forma de escrita dos distritos como “Vila-Real” e “Vila Real” e até “Castelo-Branco” e “Castelo Branco”.

Esta distribuição desigual e a presença de erros justificam a necessidade de padronizar os nomes das localizações e de agrupar as categorias de forma correta. O objetivo é criar um fator explicativo geográfico que seja estatisticamente robusto

para medir o impacto da localização, focando a capacidade preditiva do modelo nos distritos mais representativos da amostra.

Distribuição por área




Gráfico 5 - Frequência da Área dos imóveis

A variável Área encontra-se em formato de texto (*string*), devido à presença da unidade de medida metro ao quadrado, por isso é necessário realizar a sua conversão para o formato numérico (*float*) antes de qualquer análise estatística.

A Figura 6 demonstra que a distribuição é extremamente assimétrica e positiva, visto que há uma forte concentração de imóveis com áreas de pequena e média dimensão, até aproximadamente 478m², mas esta distribuição é consistente com o mercado imobiliário em Portugal.

Porém, observa-se a existência de *outliers* após uma análise mais profunda, isto é, valores considerados discrepantes e que não representam a generalidade dos imóveis residenciais, nomeadamente áreas como 3 milhões de metros quadrados ou valores superiores. Estes valores podem enviesar o modelo, comprometendo a precisão das estimativas de preço para a maioria dos imóveis.

Adicionalmente, a assimetria da distribuição sugere que a variável Área poderá beneficiar de uma transformação logarítmica (*log-transform*), tal como a variável Preço, para melhorar o desempenho do modelo.

Distribuição por preço




Gráfico 6 - Frequência de Preços dos imóveis

A variável Preço é a variável de saída (*target*), o que a torna uma variável bastante importante no modelo.

Na Figura 7, verifica-se que esta variável requer a sua conversão para o formato numérico (*float*), pois contém caracteres não numéricos como o símbolo do euro e espaços. Esta transformação deverá tratar os caracteres não numéricos e uniformizar a notação de separadores da casa decimal.

Apesar de não ser visível numa primeira observação, após uma análise mais aprofundada verifica-se que a variável é marcadamente assimétrica positiva, dado que a grande maioria dos imóveis se concentra em faixas de preços baixos. A distribuição apresenta ainda uma cauda longa, estendendo-se para valores muito mais altos.

Reparou-se também na presença de valores atípicos extremos, que poderão representar imóveis de luxo ou erros de registo visto tratarem-se de preços excessivamente elevados. Estes valores representam um desafio técnico de *data quality* que implicam a sua limpeza.

2.4. Análise da qualidade dos Dados

A análise da qualidade dos dados revelou um conjunto de inconsistências que podem distorcer a identificação dos fatores explicativos e a estimativa do valor, caso

não sejam devidamente tratados. Verificaram-se as seguintes deficiências estruturais e de formato:

- **Inconsistência de Tipos de Dados:** O principal problema reside no formato texto de *Price* e *Area*, o que impede a análise de regressão. A sua conversão é fundamental para que estas variáveis possam atuar como fatores quantitativos de valor durante a análise;
- **Valores Omissos:** Após uma verificação profunda, não foram encontrados valores omissos no *dataset* inicial, mas existem registos que não poderão ser convertidos em valores numéricos, como é o caso de algumas observações na variável *Price*, indicadas como “Preço sob consulta” e que terão de ser eliminados durante a limpeza.
- **Erros de Domínio e Padronização:** A Tipologia e a Localização demonstram graves problemas de uniformidade e erros de codificação de texto, o que exige uma limpeza de texto exaustiva para criar fatores categóricos coerentes, cujos efeitos possam ser isolados e medidos de forma eficaz.




Gráfico 7 - Relação entre o Preço e a Área dos imóveis

Para analisar a qualidade dos dados no que diz respeito aos *outliers* e à relação entre o Preço e a Área, é indispensável uma visualização bivariada.

Na Figura 7, é evidente que existe uma correlação positiva entre ambas as variáveis, ou seja, à medida que a área do imóvel aumenta o preço do mesmo também aumenta, confirmando que a Área é uma variável útil para explicar o valor de mercado.

O objetivo principal do gráfico, é analisar a presença de *outliers*, uma vez que existem preços na ordem dos milhares de milhões, sendo o preço máximo 2.5 mil milhões de euros e que deverão ser excluídos para permitir uma análise rigorosa e confiável.

É também necessário ter em atenção as áreas e preços irrealisticamente baixos, tal como áreas inferiores a 1m² ou superiores a 5.000m² e que deverão também estes ser eliminados por não representarem transações válidas no mercado imobiliário. Para além disso, verificam-se observações onde o preço é excessivamente alto e que apresentam uma área bastante reduzida (*outliers* verticais) ou, pelo contrário, imóveis com áreas enormes e com preços bastante reduzidos (*outliers* horizontais).

A verificação profunda da qualidade dos dados é um passo essencial para garantir a confiabilidade e a robustez do conjunto final de dados, preparando-o para a modelação dos fatores explicativos do valor de venda.

3. Preparação dos dados

3.1. Seleção dos dados

Feita a análise de toda a informação disponível nos *dataset* selecionados, realizou-se a escolha dos dados que serão úteis para a elaboração do projeto. O processo teve por base critérios alinhados com os objetivos definidos e os princípios de *Data Mining*, considerando a qualidade, relevância e restrições técnicas identificadas.

Foram seguidas as seguintes etapas durante o processo de seleção dos dados:

1. **Definição de objetivos:** Procedeu-se à validação dos objetivos do estudo, de modo a garantir que o conjunto de dados selecionado fosse estritamente pertinente às questões que se pretendiam abordar.
2. **Relevância das variáveis:** Foram identificadas as variáveis fundamentais para o estudo, tendo em consideração as hipóteses formuladas e as questões de análise. No contexto da avaliação do mercado imobiliário, as variáveis chaves são a *Price* e *Area*, que são essenciais para a modelação preditiva. As

variáveis *Type* e *Property* são variáveis categóricas cruciais para o desenvolvimento do modelo, pois são características que distinguem os imóveis. Por fim, a variável *Location* é uma variável descritiva que será relevante para o projeto, dado que o mercado imobiliário é altamente influenciado por fatores geográficos.

3. **Seleção de Registos:** Definiu-se que se irá incluir a totalidade dos registos que cumpram os requisitos mínimos de integridade, de forma a garantir a significância estatística durante as análises regionais.
4. **Amostragem e Separação:** O conjunto final foi preparado para que, posteriormente seja dividido em dados de treino (80%) e teste (20%), assegurando que o modelo trabalha com uma amostra representativa e validável.

Escolheu-se esta estrutura devido à imprescindibilidade de unir as duas bases de dados originais para criar um único *dataset* fidedigno e que retrate fielmente o mercado imobiliário português. Esta abordagem permitiu melhorar a qualidade dos dados para o nível exigido pelas técnicas a aplicar.

Deste modo, definiu-se que os dados a serem incluídos na análise de estudo são todas as variáveis existentes e as criadas, nomeadamente:

- *Type*
- *Location*
- *Property*
- *Area*

3.2. Limpeza dos Dados

Recorreu-se à linguagem de programação *Python* para a realização da limpeza dos dados, assegurando a preparação do *dataset* para análises futuras a serem realizadas. As ações implementadas focaram-se na normalização técnica das variáveis.

Para juntar os dois conjuntos de dados, teve de se proceder à uniformização da variável *Area* e *Price*, conforme o anexo 2, dado que o ponto é considerado um separador decimal ou um separador de milhar, respetivamente. Definiu-se que, caso se verifique ser um apartamento, o ponto mantém-se e assume o formato de

separador decimal, mas caso se verifique tratar-se de uma casa este é assumido como separador de milhar e é removido, e a vírgula existente no número é substituída por um ponto, para que seja o separador decimal.

Na variável *Location*, foi realizada a limpeza e uniformização das várias localidades mencionadas, como é visível no anexo 3. Devido a caracteres especiais como acentos e hífens e a utilização de frases como “Apartamento para venda” existia um agrupamento bastante irreal dos imóveis. Para remover o ruído observado, foi implementado um dicionário de mapeamento para corrigir erros de codificação, utilizando a biblioteca *unidecode*, de modo a garantir a integridade referencial das diversas localizações. Além disso, as ilhas do arquipélago dos Açores foram organizadas num só grupo denominado “Açores”.




Gráfico 8 - Frequência da localização dos imóveis (dados limpos)

Foi também realizado o tratamento dos *outliers* que distorciam as métricas centrais do conjunto de dados, existentes na variável *Price* (ex: linhas onde os imóveis custavam acima de 1 bilhão de euros, ou linhas cujo o preço estaria sob consulta e representavam valores omissos ou 0 euros nesta análise), eliminando as linhas onde estes constavam. observado no anexo 4.

Por fim, na variável *Area* foi ainda aplicado um filtro de limpeza de modo a eliminar casos onde a área é zero, negativa ou apenas “lugares de garagem” que por vezes são misturados aos restantes anúncios, deixando apenas as habitações com uma área mínima real (neste caso, superiores a 10m²). Adicionalmente, realizou-se a remoção de observações com áreas superiores a 5.000m² que se revelaram ser terrenos agrícolas ou erros de inserção, uma vez que a tipologia observada é bastante

baixa (0, 1 ou 2) em comparação à grande área, não se enquadrando na categoria de habitação urbana pretendida.

Os dados identificados como “sujos” e que não foram possíveis tratar como os restantes foram convertidos em valores omissos e, posteriormente removidas todas as linhas onde estes permaneceram.

A remoção verificada de *outliers* deveu-se à necessidade de proteger o modelo de distorções estatísticas que poderiam acontecer, caso o modelo fosse treinado com estes valores.

Todos os passos do processo foram devidamente documentados, e as capturas de ecrã encontram-se em anexo, ilustrando as transformações supramencionadas.

3.3. Construção dos dados

A etapa da construção dos dados envolve a transformação dos atributos e variáveis, de modo a melhorar o *dataset*, e a performance das técnicas a utilizar e facilitar a descoberta de padrões não-lineares.

Atributos Derivados e Transformações

Devido à assimetria identificada na AED na distribuição das variáveis, aplicou-se a transformação logarítmica para normalizar *Price* e *Area*, como se vê no anexo 5. Esta ação é imprescindível para aproximar a distribuição dos dados da normalidade, garantindo a eficácia da Regressão Linear.




Gráfico 9 - Distribuição Normalizada da variável Price e Area

Após a aplicação da transformação logarítmica, observa-se na Figura 8 que as variáveis *Price* e *Area* passaram a apresentar uma distribuição próxima da normalidade. No gráfico de Log_Price, a maior concentração de dados situa-se entre os valores 12 e 13 (160k€ a 440k€), eliminando a assimetria positiva severa observada nos dados brutos. Esta normalização é fundamental para satisfazer os pressupostos do modelo de Regressão Linear Múltipla que será aplicado adiante e permite que o modelo estime variações percentuais o que é mais consistente com a realidade económica do mercado. Sem estas transformações, o MAE seria bastante superior.

O atributo *Type* foi submetido a um processo de mapeamento para a uniformização entre os dois conjuntos de dados (anexo 6), de forma a ser possível realizar a comparação entre ambos. Este processo converteu os diversos formatos existentes nesta categoria para o padrão x, como observado na Figura 9, envolvendo a soma de tipologias compostas como T2+1 convertendo as para a respetiva tipologia correta e *Studios* para o valor 0, garantindo uma escala numérica contínua de 0 a 10 para o modelo. Esta transformação garante que o modelo trata a variável como numérica e entende que um imóvel com 2 quartos é “menor” que um imóvel com 3 quartos.




Gráfico 10 - Frequência das tipologias (dados limpos)

O conjunto de dados demonstrou integridade nesta etapa, uma vez que os valores omissos foram eliminados anteriormente. Combinada com a uniformização

categórica e geográfica, assegura-se que todos os atributos estão no formato mais adequado e otimizado para a próxima fase.

Por último, procedeu-se à codificação de variáveis categóricas para que se pudesse aplicar a técnica preditiva pretendida, utilizando a técnica *One-Hot Encoding* (variáveis *dummy*). Com este procedimento, transformaram-se as variáveis *Location* e *Property* em múltiplas colunas binárias. Assim, cada localização e tipo de imóvel passou a estar representado de forma numérica, permitindo que o algoritmo de Regressão Linear seja capaz de processá-las sem atribuir uma ordem de importância entre elas.

3.4. Integração dos dados

A etapa de integração consistiu na integração estrutural de dois domínios distintos, porém complementares, necessárias para o desenvolvimento do modelo. Este procedimento foi efetuado numa fase inicial do tratamento dos dados para garantir que a limpeza e os filtros de *outliers* fossem aplicados de forma uniforme a ambos os *dataset*, através da concatenação vertical dos mesmos, o que permitiu obter uma representação abrangente e fidedigna do mercado imobiliário para a modelação.

A coluna *Property* foi criada antes da união das duas bases de dados, de modo a não se perder a informação de qual era o tipo original de cada imóvel durante a concatenação. Esta ação gerou um novo registo, totalizando 36.976 linhas, o que permitiu que a limpeza e os filtros fossem aplicados a toda a amostra sem prejudicar os resultados.

Atividades de consolidação

Verificaram-se as colunas em comum entre as duas bases de dados de forma a garantir que a integração não criava espaços vazios ou observações duplicadas.

Esta etapa garantiu a harmonização entre os modelos, para que pudessem processar o mercado imobiliário português como um todo, tratando a categoria do imóvel como um fator explicativo categórico.

3.5. Formatação dos dados

Reformatação técnica

O conjunto de dados foi formatado de modo a garantir a consistência e a compatibilidade com as técnicas analíticas a aplicar. Mais concretamente, foi realizada a alteração sintática dos dados de forma a assegurar a compatibilidade total com as ferramentas de modelação e garantindo a integridade da informação durante a exportação.

O *dataset* final foi guardado em formato *.csv* com codificação *utf-8-sig* de modo a permitir a compatibilidade entre o ambiente *Python* e o *Microsoft Excel*, assegurando que os caracteres especiais da língua portuguesa sejam lidos sem erros, como é o caso de acentos e cedilhas.

Organização de atributos

De acordo com a metodologia adotada, os atributos foram organizados de modo a que a variável de saída, *Price*, fosse claramente identificada para a ferramenta de modelação.

De referir que o conjunto de dados foi exportado para um novo ficheiro *.csv*, para que fosse possível obter um *dataset* final preparado e pronto para o início da fase de modelação.

4. Modelação

A fase de modelação constitui o núcleo analítico do projeto, onde são aplicadas técnicas de aprendizagem automática sobre os dados previamente preparados. O primeiro passo é escolher qual ou quais as técnicas que serão utilizadas. Em cada técnica, existirão parâmetros que deverão ser definidos para valores otimizados (Belfo, 2022).

A modelação é dividida em 4 etapas:

1. **Selecionar as técnicas de modelação:** Identificação dos algoritmos de regressão mais adequados para proceder à análise dos dados escolhidos

durante a seleção realizada, de modo a escolher as técnicas de modelação adequadas e relevantes para o projeto.

2. **Criar uma conceção de testes:** Definição de estratégias de validação do modelo, garantindo a robustez e precisão do mesmo.
3. **Construção do modelo:** Execução técnica dos algoritmos, de modo a que o modelo aprenda a relação entre as variáveis.
4. **Revisão do modelo:** Realização de uma análise detalhada do modelo desenvolvido, com o intuito de avaliar as técnicas seleccionadas e a eficácia e fiabilidade dos resultados obtidos.




Figura 3 - Tarefas da fase Modelação

4.1. Seleção das técnicas de modelação

A escolha das técnicas de modelação a serem utilizadas é ditada pela natureza da variável dependente do projeto, neste caso o *Price*. Dado que o objetivo principal é prever o preço de venda dos imóveis, uma variável numérica contínua, a tipologia de modelação seleccionada primeiramente é a Regressão.

Optou-se pela utilização da Regressão Linear Múltipla como modelo base. Esta técnica foi seleccionada como modelo de referência, pois permite quantificar o peso de cada variável explicativa no preço final do imóvel, facilitando a compreensão dos

fatores que mais o valorizam. Segundo Belfo (2022), esta é uma escolha essencial para que seja possível uma interpretação clara dos dados.

Esta técnica exige o cumprimento de alguns pressupostos. Primeiro, assume-se que as variáveis seguem uma distribuição próxima da normalidade, um pressuposto garantido através da transformação logarítmica realizada anteriormente. O segundo pressuposto é a independência de atributos, isto é, as variáveis geográficas e estruturais fornecem contributos independentes para a estimativa de valor.

Para complementar o projeto e tentar ultrapassar as limitações de linearidade, será aplicada uma técnica não-linear. Enquanto as abordagens baseadas em Regressão Linear assumem uma relação direta e constante entre as variáveis explicativas e o preço (linearidade), a natureza do mercado imobiliário apresenta frequentemente comportamentos mais complexos. Fenómenos como a valorização exponencial de imóveis de luxo ou a descontinuidade abrupta de preços entre concelhos vizinhos são difíceis de captar apenas com linhas retas.

Para responder a este desafio, selecionou-se como segunda técnica de modelação o algoritmo Árvore de Decisão. A estratégia adotada consiste no treino de um Modelo Global Unificado, capaz de processar a totalidade dos dados nacionais num único algoritmo, em contraposição à segmentação manual por distritos.

Apesar da existência de um modelo linear global e outro modelo segmentado, a complexidade do mercado imobiliário sugere a necessidade de uma abordagem não-paramétrica. A seleção do algoritmo Árvore de Decisão para esta fase justifica-se por três limitações específicas da Regressão Linear que a Árvore de Decisão consegue ultrapassar:

- A Regressão Linear assume que o preço aumenta de forma constante e proporcional. No entanto, o mercado real não funciona assim, pois existem patamares de preço e "saltos" abruptos, como é o caso de o preço disparar desproporcionalmente a partir de certa área ou em zonas de luxo. A Árvore de Decisão modela estes comportamentos através de uma estrutura, que se adapta melhor a estas flutuações irregulares.
- Um modelo Linear Global trata as variáveis de forma independente. A Árvore de Decisão, pelo contrário, deteta Regras Condicionais, o algoritmo pode

perceber que a variável Área tem um peso diferente se a casa for um T4, onde cada m² vale mais do que se for um T1. Esta capacidade de ajustar a importância das variáveis consoante o contexto, sem intervenção manual, é a grande vantagem da Árvore de Decisão sobre a Regressão Linear Global.

- Enquanto a Regressão Linear é matematicamente forçada a desviar a sua "linha" para tentar acomodar valores extremos, a Árvore de Decisão isola esses casos em "ramos" específicos. Isto permite proteger a regra geral de decisão da influência de imóveis com preços anormais, criando regras específicas para eles.

Para a árvore de decisão, assume-se a urgência de fixar a profundidade máxima para diminuir o risco de *overfitting* e assegurar que o modelo aprende padrões generalizáveis em vez de memorizar ruído.

4.2. Geração do desenho de testes

Foi aplicado um teste rigoroso baseado no método de divisão de dados (*Hold-out*), para avaliar o desempenho e a capacidade de generalização do modelo. Esta ação é crucial para garantir que o modelo identifica os padrões reais existentes nos dados sem sofrer sobre ajustamento..

A divisão do *dataset* que contem 31.830 observações foi feita em duas partes independentes. A primeira trata-se do conjunto de treino, onde se encontram 80% das observações (25.464 casos), utilizado para ajustar os parâmetros da regressão linear, permitindo que o algoritmo aprenda a relação entre a área, localização e tipologia com o preço do imóvel. A segunda denomina-se conjunto de testes, contendo os restantes 20% dos dados (6.366 casos), e é reservado apenas para a validação final, isto é, o modelo realiza previsões consoante os padrões encontrados no conjunto de treino, e os resultados são comparados com os preços reais.

Preferiu-se utilizar uma divisão 80/20 porque o *dataset* tem cerca de 31000 casos, o que significa que 20% destes casos são suficientes para um teste robusto, permitindo que o modelo tenha 80% para aprender o máximo possível sobre as variações de preço dos imóveis.

Adicionalmente, para garantir que os resultados são reproduzíveis, utilizou-se um *random state* = 42. Esta configuração permite que a partição entre os conjuntos de treino e teste seja semelhante em todas as execuções do código. Esta medida é

importante, pois confirma que outras técnicas de modelação sejam testadas nas mesmas observações, possibilitando uma comparação justa e rigorosa entre diferentes algoritmos.

4.3. Implementação e Resultados: Regressão Linear

Nesta etapa, procedeu-se à implementação prática da regressão linear múltipla. O modelo foi treinado na etapa anterior, utilizando as variáveis independentes do *dataset* para prever o variável dependente e cumprir o objetivo do projeto, prever o preço dos imóveis no mercado português.

4.3.1. Regressão Linear Global

Inicialmente, aplicou-se o modelo a todo o *dataset* (anexo 7), ou seja, ao conjunto de dados a nível nacional. O algoritmo obteve um Coeficiente de Determinação (R^2) de 0,7892, o que representa que aproximadamente 78,92% da variabilidade dos preços dos imóveis em Portugal é explicada pelas variáveis independentes do modelo (*Location, Area, Type*). Este resultado demonstra uma capacidade preditiva muito satisfatória do algoritmo, fortemente influenciada pelo desfasamento de preços entre os diversos distritos e regiões autónomas em estudo.

Calculou-se também o MAE para quantificar a precisão do modelo em termos monetários. Este valor, expressa em euros o desvio esperado entre o preço previsto pelo modelo e o preço real de mercado.

Neste caso, o MAE é de 77.903,98€ que, quando analisado em termos relativos face ao preço médio da amostra, este valor representa um erro médio de apenas 15,93%. Assim, conclui-se que o algoritmo tem uma precisão média de cerca de 84% o que se revela um indicador de elevada fiabilidade. Este resultado realça que, apesar da simplicidade do modelo linear, as variáveis independentes selecionadas permitem entender a lógica fundamental de fixação de preços no mercado imobiliário português.

Complementarmente, calculou-se o RMSE, obtendo-se um valor de 109.455,19 €. A comparação entre estas duas métricas revela um detalhe importante sobre a *performance* do modelo, o facto de o RMSE ser superior ao MAE, uma diferença de aproximadamente 32.000€, indica a presença de *outliers* na previsão. Ou seja, embora o modelo linear seja bastante assertivo para a maioria das

habitações, ele tende a cometer erros de maior magnitude em imóveis com preços muito elevados ou características atípicas, onde a relação linear deixa de ser suficiente para explicar o valor real. Esta sensibilidade aos extremos valida, mais uma vez, a pertinência de avançar para modelos não-lineares na fase seguinte do projeto.

Não obstante, a existência desta margem de erro justifica a exploração de modelos mais complexos, de modo a tentar capturar os fatores qualitativos que a regressão linear não consegue processar.

4.3.2. Regressão Linear por Localização

De forma a aprofundar a análise, realizou-se a segmentação do *dataset* pela localização dos imóveis (anexo 8), gerando 18 modelos independentes. Esta ação possibilitou a observação da eficácia da regressão linear em mercados mais homogêneos, cujos resultados se encontram na Tabela 1.

É de referir que foi aplicado um filtro para que apenas se aplicasse o modelo caso existissem mais de 50 imóveis na mesma localização, garantindo que existiam dados suficientes para a aplicação do algoritmo. Por isso, não foi realizado nenhum modelo para os Açores, pois este critério não se verificava.

Distrito	R2	MAE (€)	Amostra (n)
Setúbal	0.53	102.295,89	2678
Braga	0.52	86.437,06	2009
Bragança	0.46	72.920,46	243
Santarém	0.43	106.330,18	1447
Castelo Branco	0.43	91.585,85	890
Porto	0.34	125.226,94	6524
Évora	0.32	163.318,92	567
Faro	0.31	147.085,47	2845
Viana do Castelo	0.28	110.126,11	1609
Ilha da Madeira	0.26	140.267,60	327
Portalegre	0.26	130.908,17	602
Viseu	0.22	135.030,46	583
Aveiro	0.22	125.204,69	2201
Leiria	0.21	165.963,40	1674
Lisboa	0.21	194.852,05	4435
Coimbra	0.20	118.765,75	1619
Guarda	0.19	97.699,19	387
Beja	0.18	180.637,15	642
Vila Real	0.15	139.446,33	514

Tabela 2 - Desempenho da Regressão Linear por Localização

Ao analisar os resultados obtidos por Localização, repare-se que Vila Real apresenta o R^2 mais baixo dos modelos válidos (0.15), seguido por Beja (0.18). Na

capital, o valor explicativo é de 0.21, apesar de possuir uma amostra robusta (4.435 observações). Este valor sugere que em Lisboa o preço não é somente ditado pela *Area* ou *Type*, visto que existem outros fatores relevantes para a fixação do preço, como a proximidade a transportes públicos, ter ou não vista de rio ou até o facto de ser um prédio histórico recuperado. Por isso, o modelo linear “falha” nesta localidade porque o mercado é demasiado heterogéneo.

Por outro lado, Setúbal (0.53) e Braga (0.52) apresentam o R^2 mais elevados, uma vez que o mercado residencial nestas zonas parece seguir uma lógica mais previsível e tradicional. Aqui, o aumento da área e do número de quartos num imóvel traduz-se num aumento proporcional e linear do preço, por se tratarem de mercados menos especulativos e que permitem à Regressão Linear ser mais assertiva. Estes valores de coeficientes de determinação superiores a 0.50 indicam que o modelo já consegue explicar mais de metade da variação dos preços, conferindo maior fiabilidade ao modelo.

É ainda relevante notar o caso de Bragança que embora tenha um R^2 de 0.46, possui uma amostra bastante reduzida (243 observações). Não obstante, o facto de ter o MAE mais reduzido do estudo (72.920,46€), demonstra que os preços neste distrito são mais baixos e menos voláteis, possibilitando uma convergência mais fácil da linha de regressão.

Analisando o MAE, percebe-se que em Lisboa (194.852,05€) é quase o dobro do de Setúbal (102.295,89€) o que não significa necessariamente que o modelo falha mais na primeira localização. Ao ler estes valores, deve-se ter em consideração que na capital os preços dos imóveis são drasticamente superiores. Não obstante, um erro médio próximo a 200.000€ enfatiza a necessidade de um modelo mais robusto para cidades com esta complexidade.

Em síntese, a realização do modelo segmentado por localização demonstra que Portugal não é um país com um mercado imobiliário único e estático, mas sim uma união de mercados regionais com comportamentos e características distintas. A incapacidade da Regressão Linear em explicar de forma satisfatória a variância de preços em Lisboa e no Porto (0.34) confirma que existem outras variáveis como acesso a transportes, estado de conservação e prestígio da zona são essenciais nestas áreas, justificando a mudança para modelos não-lineares mais flexíveis e complexos, como as Árvores de Decisão.

4.4. Implementação e Resultados: Árvore de Decisão

A construção do modelo de Árvore de Decisão seguiu uma metodologia rigorosa de otimização de hiperparâmetros, visando mitigar o risco de *overfitting*, ajuste excessivo aos dados de treino, comum neste tipo de algoritmo.

Iniciou-se pela definição do espaço de pesquisa dos hiperparâmetros, uma etapa de extrema importância, dado que este algoritmo é altamente sensível à calibração da sua profundidade máxima. A ausência de limites impostos ao crescimento da árvore levaria inevitavelmente ao fenómeno de *overfitting*, onde o modelo memoriza o ruído específico dos dados de treino em vez de aprender padrões generalizáveis, resultando numa *performance* fraca em novos dados. Pelo contrário, uma restrição excessiva, árvores demasiado rasas, resultaria em *underfitting*, incapacitando o modelo de captar as nuances e não-linearidades do mercado imobiliário.

Neste sentido, para garantir o equilíbrio ideal entre viés e variância e assegurando a comparabilidade rigorosa com o modelo linear desenvolvido na fase anterior, através da utilização da mesma configuração, *random state = 42* e da divisão teste de 80/20, estabeleceu-se um intervalo de pesquisa para a profundidade da árvore entre 3 e 20 níveis. Esta abordagem permite ao algoritmo explorar um espectro abrangente, desde estruturas simplificadas de fácil interpretação até arquiteturas mais complexas capazes de detetar interações profundas entre as variáveis.

Em detrimento de uma seleção empírica ou arbitrária da profundidade da árvore, implementou-se uma estratégia de otimização sistemática de hiperparâmetros recorrendo ao algoritmo *GridSearchCV*. O objetivo central desta etapa foi identificar a configuração estrutural que maximiza a precisão do modelo sem comprometer a sua capacidade de generalização para novos dados.

Para tal, definiu-se um espaço de pesquisa para o hiperparâmetro (*max_depth*) compreendido no intervalo de números inteiros entre 3 e 20. De forma a garantir a robustez estatística dos resultados e evitar enviesamentos decorrentes de uma divisão de dados específica, o processo de treino incorporou a técnica de validação cruzada, *k-fold Cross-Validation*, com 5 iterações, $k=5$. Deste modo, para cada profundidade testada, o modelo foi treinado e validado cinco vezes em subconjuntos distintos dos dados, sendo a métrica final a média do desempenho nessas iterações. Esta abordagem assegura que a profundidade selecionada é consistentemente a

mais eficaz e não fruto de uma aleatoriedade favorável na distribuição dos dados de treino.

A execução do processo de pesquisa exaustiva na grelha de hiperparâmetros identificou que a profundidade ideal para a árvore de decisão global é de 7 níveis. A análise dos resultados de validação sugere que este valor representa o ponto de equilíbrio ótimo (*trade-off*) entre viés e variância, abaixo deste nível, o modelo apresentava sinais de *underfitting*, sendo demasiado simplista para captar a complexidade do mercado, acima deste nível, os ganhos marginais de precisão não compensaram o aumento do risco de *overfitting* e a perda de interpretabilidade.

Com base neste hiperparâmetro calibrado ($\text{max_depth}=7$), procedeu-se ao treino definitivo do modelo sobre a totalidade do conjunto de treino. A avaliação subsequente nos dados de teste revelou um coeficiente de determinação (R^2) de 0,442. Este indicador quantifica a capacidade do modelo em explicar aproximadamente 44,2% da variabilidade total dos preços, constituindo o resultado final a ser submetido à análise comparativa de desempenho na fase seguinte do projeto.

O código realizado para a preparação deste modelo encontra-se no anexo 9.

4.4.1. Interpretação da Estrutura da Árvore

A avaliação da *performance* do modelo global de Árvore de Decisão incidiu sobre duas dimensões complementares, a interpretação qualitativa da estrutura de decisão gerada e a análise quantitativa das métricas de erro.

A visualização gráfica do modelo, apresentada na figura 12, permite compreender a hierarquia de regras que este definiu autonomamente para estimar o valor dos imóveis. A análise dos níveis superiores da árvore revela a seguinte lógica de segmentação de mercado:

- **Raiz:** A variável escolhida pelo algoritmo para o topo da hierarquia, ou seja, aquela que maximiza a separação inicial de preços, é a área ($\text{Area} \leq 172.0$). Esta decisão segmenta imediatamente o mercado imobiliário nacional em dois grandes grupos distintos, as habitações com área inferior a 172 m² e as habitações com área superior a 172 m².

- **Ramificação Esquerda:** Para os imóveis identificados como tendo área inferior ou igual a 172 m², caminho "True", o critério discriminante seguinte é a Localização (Location_Lisboa). Este nó contém a maior parte da amostra, 18.715 amostras, e apresenta um valor médio predito de 359.192,00€ que é substancialmente inferior à média global. Isto indica uma correlação positiva entre área e valor, áreas menores tendem a ter valores menores.
- **Ramificação Direita:** Inversamente, para os imóveis com area superior a 172 m², caminho "False", tal como na ramificação da esquerda o modelo mantém a sua prioridade, elegendo a Localização (Location_Lisboa), como o fator crítico de decisão. Este nó contém um número menor de amostras, 8.094, o valor médio dispara para 747.439,00€. Isto confirma a premissa de que imóveis acima de 172 m² de área possuem um valor de mercado significativamente superior.

O modelo da Árvore de Decisão encontra-se no anexo 10.

4.5. Análise Comparativa de Desempenho

A quantificação do erro revela um comportamento distinto entre os dois modelos aplicados, enfatizando a complexidade do mercado imobiliário português.

A Regressão Linear apresentou métricas de erro mais moderadas, com um MAE de 77.903,98€ e um RMSE de 109.455,19€, indicando que, estatisticamente, a abordagem linear global consegue aproximar-se melhor da média de preços do mercado corrente.

Em contrapartida, o modelo de Árvore de Decisão registou um MAE de 197.739,50 €, isto é, em média, as previsões desviam-se do valor real neste valor. Contudo, a discrepância substancial para o RMSE de 425.299,32 € que se apresenta mais de duas vezes superior ao erro absoluto é o indicador mais crítico desta análise. Esta diferença acentuada confirma que o desempenho do modelo não é uniforme, enquanto a previsão é razoavelmente estável para a generalidade dos imóveis, refletida no MAE, a Árvore de Decisão é severamente penalizada por erros de grande magnitude em propriedades de luxo ou atípicas, captados pelo RMSE.

Em suma, conclui-se que a Regressão Linear estabeleceu uma base sólida e eficiente para prever o mercado imobiliário, dado o seu MAE significativamente inferior. No entanto, a Árvore de Decisão, embora apresente maior sensibilidade a *outliers*, provou ser superior na identificação de regras de segmentação crítica como é o caso da forte assimetria causada pela localização em Lisboa e o escalão da tipologia.

Esta dualidade prova que a complexidade do mercado português não é uniforme e, por isso, o modelo linear serve a maioria das transações, contudo a flexibilidade da árvore é essencial para absorver as descontinuidades e os fatores de exceção que caracterizam zonas de maior pressão urbanística e segmentos de luxo.

5. Avaliação

5.1. Avaliação de resultados

Nesta etapa de avaliação, confrontam-se os resultados da Regressão Linear Múltipla com os da Árvore de Decisão, visando aferir qual o modelo que melhor traduz a realidade do mercado imobiliário nacional.

5.1.1. Análise comparativa de desempenho preditivo

A Tabela 3 sintetiza as métricas estatísticas recolhidas após o treino e teste de ambos os modelos.

Métrica	Regressão Linear	Árvore de Decisão
R ² (Qualidade)	78,92%	44,20%
MAE (Erro Médio)	77.903,98 €	197.739,50 €
RMSE (Robustez)	109.455,19 €	425.299,32 €

Tabela 3 - Comparação de métricas entre os modelos preditivos

A análise da mesma revela um paradoxo estatístico uma vez que, embora a Regressão Linear apresente métricas de erro inferiores (MAE de 77.903,98€ e RMSE de 109.455,19€), o seu desempenho reflete apenas a tendência central e linear do mercado (por exemplo, a relação entre a área e o preço). Em contraste, a Árvore de Decisão ($R^2=0.442$), apesar de apresentar desvios mais elevados, oferece uma

estrutura mais próxima da realidade do negócio ao permitir a segmentação do mercado imobiliário português segundo tipologias e localizações críticas, como Lisboa.

Observa-se, contudo, uma discrepância acentuada entre o MAE e o RMSE em ambos os modelos, sendo este efeito particularmente crítico na Árvore de Decisão (MAE de 197.739,50,31€ e RMSE de 425.299,32 €), uma vez que a variação, próxima do dobro, confirma a presença de *outliers* de elevada magnitude que resistiram à limpeza. Os modelos demonstram fiabilidade no segmento de habitação corrente, mas a precisão é comprometida no mercado de luxo ou em propriedades atípicas, onde fatores qualitativos e a exclusividade se sobrepõem à lógica das variáveis quantitativas tradicionais.

Concluindo, embora a Regressão Linear demonstre à primeira vista erros mais baixos, a Árvore de Decisão é superior no que diz respeito à capacidade de segmentação e adaptação a fatores de exceção que representam o mercado português

5.1.2. Diagnóstico de erros e impacto de outliers

A análise detalhada da estrutura de erro revela que a precisão dos modelos não é uniforme em todos os segmentos do mercado. Conforme evidenciado pela relação entre o MAE e o RMSE, existe uma sensibilidade acentuada a valores extremos que compromete a performance estatística global.




Gráfico 11 - Comparação entre o erro médio absoluto e a raiz do erro quadrático médio

A disparidade observada no Gráfico 11, onde o RMSE da Árvore de Decisão atinge o valor de 425.299,32 €, indica que o erro quadrático é fortemente inflacionado por um número reduzido de previsões de imóveis de luxo. Esta leitura é confirmada pela análise do Gráfico 12, que ilustra um fenómeno de heterocedasticidade uma vez que os imóveis de valor baixo e médio apresentam uma nuvem de pontos concentrada em torno da linha de regressão. No entanto, a aplicação da transformação logarítmica foi fundamental para normalizar esta variância, de modo a possibilitar que o modelo de Regressão mantivesse uma performance superior à da Árvore de Decisão, que se mostrou com maior sensibilidade aos extremos.




Gráfico 12 - Dispersão entre valores reais e previstos no modelo de Árvore de Decisão

É visível a presença de *outliers* extremos no topo do gráfico, onde as previsões atingem a escalas de 14.000.000€ (1.4×10^7), revelando um desvio significativo face à linha de identidade. Esta discrepância demonstra que imóveis de luxo não seguem métricas quantitativas comuns, sendo influenciados por fatores de prestígio e exclusividade que a base de dados atual não capta.

Estatisticamente, este comportamento comprova que as variáveis quantitativas utilizadas (Área, Tipologia e Localização) são suficientes para modelar o mercado habitacional corrente, mas tornam-se insuficientes perante a exclusividade do segmento de luxo. Nestes casos, o valor do imóvel é determinado por atributos qualitativos e subjetivos não captados pelo *dataset*, resultando em *outliers* que desviam a média de erro e reduzem o coeficiente de determinação global, uma vez que a variância nestes patamares elevados é muito difícil de prever de forma linear ou por regras de segmentação simples.

5.1.3. Validação das regras de decisão e relevância das variáveis

A análise da importância das variáveis, detalhada no Gráfico 13, revela uma hierarquia de decisão muito específica e afunilada. Ao contrário do esperado numa análise linear simples, a árvore de decisão identificou três fatores críticos que detêm quase a totalidade do peso preditivo do modelo.




Gráfico 13 - Hierarquia de importância das variáveis no modelo de árvore de decisão

A observação dos dados revela que Área (62%), surge como determinante absoluto de valor, seguido pela Localização do imóvel em Lisboa (12%) e pela

Localização do imóvel no Porto (8%). Esta distribuição valida a eficácia do tratamento de dados realizado:

- **Dominância regional:** o facto de Lisboa e Porto serem variáveis explicativas com peso significativo indica que o modelo detetou uma assimetria regional de valor tão elevada que esta anula o impacto estatístico das outras regiões no conjunto de dados.
- **Segmentação por tipologia:** a importância do *Type* sugere que a distinção entre apartamento e moradia é um filtro de valor superior à própria metragem isolada.
- **Impacto da Area:** Ao aplicar os filtros à variável *Area*, esta variável passou a ter um peso relevante, demonstrando uma relação direta e muito forte com o preço dos imóveis.

5.1.4. Diagnóstico de fiabilidade por segmento de mercado

A eficácia dos modelos desenvolvidos não é uniforme, sendo diretamente influenciada pela hierarquia de variáveis identificada. Ao cruzar a dispersão de preços com a importância dos atributos, observa-se que o modelo de árvore de decisão opera com elevada precisão apenas no mercado de habitação *standard*.

Segmento de Mercado	Comportamento no Gráfico Z
Habitação de gama standard	Elevada densidade junto à linha de identidade
Habitação de gama média/alta	Dispersão moderada (Erro cresce com a área)
Habitação de gama luxo	Erros extremos (Outliers até 14M €)

 Nível de confiabilidade elevada	 Nível de confiabilidade média
	 Nível de confiabilidade nula

Tabela 4 - Matriz de confiabilidade final

O erro de escala observado no ponto 5.1.2, onde as previsões atingem patamares de 14 milhões de euros, deve-se à configuração de pesos identificada no ponto 5.1.3. Verifica-se que a atribuição de um peso de 62% ao atributo da *Area*,

quando combinada com o coeficiente de localização de Lisboa (12%) leva o modelo a priorizar a dimensão e a localização do imóvel em detrimento de variáveis qualitativas. Esta iteração resulta na inflação irrealista dos valores previstos pelo modelo sempre que se verifica a existência de um imóvel com uma área elevada numa localização de elevada pressão imobiliária.

5.2. Revisão do processo

Nesta fase final do ciclo CRISP-DM, realizou-se uma auditoria crítica à execução do projeto face aos objetivos estratégicos definidos na Etapa 1. O objetivo central, que foi quantificar o impacto dos determinantes de preço no mercado residencial português foi cumprido com sucesso, traduzindo-se num modelo capaz de explicar as variações de valor com base em métricas quantitativas e geográficas.

A análise do processo revela que a preparação dos dados foi a fase mais determinante. A decisão de aplicar transformações logarítmicas às variáveis de área e preço revelou-se correta, permitindo mitigar a heterocedasticidade e a assimetria inerentes ao mercado imobiliário. Contudo, a revisão identifica uma limitação estrutural, pois embora o modelo base apresente uma performance sólida para a habitação convencional, a ausência de variáveis qualitativas (ex: estado de conservação, certificação energética ou ano de construção) impede uma captura mais precisa da variância no segmento premium.

Em suma, o processo foi tecnicamente robusto e seguiu rigorosamente o planeamento, mas os resultados reforçam a necessidade de transcender os dados públicos básicos para atingir um nível de precisão comercialmente competitivo.

5.3. Determinar os próximos passos

Para futuras iterações deste projeto, e com vista à evolução do modelo de um estado descritivo para uma ferramenta de apoio à decisão em tempo real, sugerem-se as seguintes linhas de investigação:

- **Enriquecimento de Atributos (Feature Engineering):** Integrar dados de pontos de interesse (POI) através de APIs (Interfaces de Programação de Aplicações) de geolocalização para medir a proximidade a serviços críticos

(hospitais, escolas e transportes públicos), fatores que o atual modelo apenas capta indiretamente através da variável "Localização".

- a) Pontos a favor: Poderá permitir a captação do valor da “conveniência”, isto é, da proximidade a transportes públicos, a supermercados, que é um dos maiores fatores que condicionam os preços dos imóveis e que o modelo atual apenas estima indiretamente.
 - b) Pontos contra: Exige a integração de APIs externas, nomeadamente o Google Maps, que irá aumentar a complexidade do processamento de dados geográficos e o custo associado.
- **Segmentação de Modelos (Clustering Pre-Modeling):** Implementar uma arquitetura de modelos segmentada. Em vez de um modelo global, a criação de sub-modelos específicos para o segmento de Luxo vs. Habitação Social permitiria ajustar os coeficientes às diferentes elasticidades-preço destes mercados.
 - a) Pontos a favor: Trataria do problema do RMSE elevado no mercado de luxo, permitindo que cada modelo se especialize num nicho específico com coeficientes mais precisos.
 - b) Pontos contra: Diminui o tamanho da amostra para cada nicho, o que poderá levar a problemas de significância estatística em distritos com menos observações.
 - **Exploração de Algoritmos Não-Lineares:** Embora a Regressão Linear tenha servido como um *baseline* eficaz, identifica-se como futuro passo o teste com modelos de *Ensemble*, como o *XGBoost* ou *Random Forest*. Estes modelos são reconhecidos pela sua capacidade de captar interações não-lineares entre variáveis que podem reduzir significativamente o MAE.
 - a) Pontos a favor: Este tipo de algoritmos consegue detetar interações complexas entre variáveis de forma automática, por exemplo, o efeito da área ser maior num imóvel com 4 quartos relativamente a um imóvel com 1 quarto.
 - b) Pontos contra: Estes modelos são muito mais difíceis de explicar aos utilizadores finais do que as estruturas visuais e intuitivas da Árvore de Decisão utilizada.

- **Análise Dinâmica Temporal:** Expandir o *dataset* para incluir uma componente de séries temporais, permitindo ao modelo ajustar-se à volatilidade mensal do mercado e prever tendências de valorização a curto prazo.
 - a) Pontos a favor: Esta introdução daria espaço ao modelo para ser uma ferramenta preditiva capaz de antecipar bolhas imobiliárias ou tendências de valorização mensal
 - b) Pontos contra: Necessita de uma recolha de dados contínua e histórica, que é bastante difícil de obter em comparação à informação “estática” do mercado.

Decisão:

Após a análise crítica dos resultados obtidos e do desempenho dos modelos de Regressão Linear e Árvore de Decisão, seguiu-se a tomada de decisão sobre o projeto, sendo as opções possíveis:

1. **Implementação:** Lançar o modelo atual existente como uma ferramenta final de avaliação imobiliária;
2. **Abandono do projeto:** Encerrar a investigação após conclusão que os dados disponíveis não permitem prever o preço dos imóveis de forma fidedigna;
3. **Refinamento:** Aceitar o modelo atual como um protótipo funcional, mas retornar à primeira fase de preparação e modelação de dados de modo a aprimorar e resolver lacunas essencialmente no segmento de luxo e nas localizações complexas.

Decidiu-se proceder ao refinamento do modelo atual, e utilizar o que já existe apenas para fins consultivos e experimentais em segmentos de habitação convencional.

Esta escolha deveu-se a vários fatores, nomeadamente a aplicabilidade demonstrada pelo modelo de Regressão Linear com uma precisão média de 84%, revelando ter valor prático para estimativas rápidas em mercados mais estáveis, como é o caso de Setúbal e Braga, não justificando o abandono do projeto no seu todo, mas que em localidades como Lisboa e Porto ainda é preciso ser trabalhado.

Para além disto, o valor do RMSE na Árvore de Decisão revela que a sua utilização imediata não seria adequada no setor de luxo, levando a avaliações erradas em valores elevados.

O modelo revelou ainda que os preços dos imóveis em Portugal não se baseiam somente em fatores quantitativos, como o *Type* e a *Area*, apesar de esta última variável ser um fator dominante. É imperativo que se tenha em consideração fatores qualitativos para a construção de uma ferramenta de modo a capturar a variância que os atributos mencionados não alcançam.

Por fim, embora o objetivo principal do projeto tenha sido cumprido, e seja possível identificar os principais fatores de preço e criar modelos preditivos, a fiabilidade do mesmo precisa de ser trabalhada para localizações com maior volatilidade de modo a garantir soluções mais robustas.

Anexos

Anexo 1 – Leitura dos *datasets* e seleção das variáveis:

```
import pandas as pd
df_apt = pd.read_csv('apartamentos.csv', delimiter=';', on_bad_lines='skip', engine='python')
df_casas = pd.read_csv('casas.csv', delimiter=';', on_bad_lines='skip', engine='python')
df_apt.columns = df_apt.columns.str.strip()
df_casas.columns = df_casas.columns.str.strip()
df_merged = pd.concat([df_apt, df_casas], ignore_index=True)
df_merged.to_csv('dataset_merged.csv', index=False)
df = df_merged
print(f"Apartamentos: {len(df_apt)} linhas")
print(f"Casas: {len(df_casas)} linhas")
print(f"Total Junto: {len(df_merged)} linhas")
```

Anexo 2 – Conversão das variáveis *Price* e *Area*:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df_bruto = pd.read_csv('dataset_merged.csv')
df_bruto['Price_Num'] = df_bruto['Price'].astype(str).str.replace('€', '').str.replace(' ', '').str.replace('\xa0', '').str.replace(',', '.')
df_bruto['Price_Num'] = pd.to_numeric(df_bruto['Price_Num'], errors='coerce')
df_bruto['Area_Num'] = df_bruto['Area'].astype(str).str.replace('m2', '').str.replace(' ', '').str.replace(',', '.')
df_bruto['Area_Num'] = pd.to_numeric(df_bruto['Area_Num'], errors='coerce')
df_plot = df_bruto.dropna(subset=['Price_Num', 'Area_Num'])
```

```
def limpar_area_final(row):
    v = str(row['Area']).replace('m2', '').replace(' ', '').strip()
    if 'Apartments' in str(row['Property']):
        v = v.replace(',', '.')
    else:
        if '.' in v and ',' in v: v = v.replace('.', '')
        v = v.replace(',', '.')
    try: return float(v)
    except: return None
```

Anexo 3 – Limpeza da variável *Location*:

```
import pandas as pd
import numpy as np
import re
import unicodedata

def limpar_localizacao(texto):
    if pd.isna(texto): return "Desconhecido"
    texto = str(texto)
    dicionario_erros = {
        'Ãlvora': 'Évora', 'AÃçores': 'Açores', 'BraganÃsa': 'Bragança',
        'SantarÃm': 'Santarém', 'SetÃbal': 'Setúbal', 'Setbal': 'Setúbal',
        'Santarm': 'Santarém', 'Vora': 'Évora', 'Set?bal': 'Setúbal',
        'Santar?m': 'Santarém', 'Bragan?sa': 'Bragança', '?ãvora': 'Évora'
    }
    for erro, correto in dicionario_erros.items():
        if erro in texto: texto = texto.replace(erro, correto)
    texto = re.sub(r'.*\s*', '', texto)
    texto = texto.replace('-', ' ')
    texto_low = texto.lower().strip()
    texto_norm = "".join(c for c in unicodedata.normalize('NFKD', texto_low) if not unicodedata.combining(c))
    ilhas = ['sao miguel', 'terceira', 'flores', 'faial', 'pico', 'sao jorge', 'santa maria', 'graciosa', 'corvo', 'acores', 'azores']
    if any(ilha in texto_norm for ilha in ilhas): return "Açores"
    distritos = {
        'evora': 'Évora', 'setubal': 'Setúbal', 'braganca': 'Bragança',
        'santarem': 'Santarém', 'castelo branco': 'Castelo Branco',
        'lisboa': 'Lisboa', 'porto': 'Porto', 'aveiro': 'Aveiro',
        'faro': 'Faro', 'beja': 'Beja', 'coimbra': 'Coimbra',
        'leiria': 'Leiria', 'guarda': 'Guarda', 'portalegre': 'Portalegre',
        'viseu': 'Viseu', 'braga': 'Braga', 'viana do castelo': 'Viana do Castelo',
        'vila real': 'Vila Real', 'madeira': 'Ilha da Madeira'
    }
    for key, value in distritos.items():
        if key in texto_norm: return value
    return texto.title()
```

Anexo 4 – Tratamento de outliers:

```
df = df.dropna(subset=['Price', 'Area', 'Type'])
df = df[(df['Price'] > 0) & (df['Price'] <= 1000000000)]
df = df[(df['Area'] > 10) & (df['Area'] <= 5000)]
```

Anexo 5 – Transformação logarítmica nas variáveis *Price* e *Area*:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df_final = pd.read_csv('dataset_merged.csv')
df_final['Log_Price'] = np.log1p(df_final['Price'])
df_final['Log_Area'] = np.log1p(df_final['Area'])
```

Anexo 6 – Normalização da variável *Type*:

```
def limpar_tipologia(valor):
    v = str(valor).lower().strip()
    if 'studio' in v: return '0'

    if '+' in v:
        numeros = re.findall(r'\d+', v)
        total = sum(int(n) for n in numeros if n.isdigit())
    else:
        match = re.search(r'\d+', v)
        total = int(match.group()) if match else -1

    if 0 <= total <= 10:
        return f'{total}'
    return None
```

Anexo 7 – Criação do Modelo de Regressão Linear Global:

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, r2_score
from sklearn.metrics import mean_squared_error

df_model = df[(df['Price'] > 0) & (df['Area'] > 0)].dropna(subset=['Price', 'Area', 'Location', 'Property']).copy()
limite_preco = df_model['Price'].quantile(0.95)
df_model = df_model[df_model['Price'] < limite_preco]
df_model['Type'] = pd.to_numeric(df_model['Type'], errors='coerce')
df_model = df_model.dropna(subset=['Type']) # Remover se algum falhou a conversão
df_final = pd.get_dummies(df_model, columns=['Location', 'Property'], drop_first=True)
X = df_final.select_dtypes(include=[np.number]).drop(['Price', 'Index'], axis=1, errors='ignore')
y = df_final['Price']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
print(f"Treino: {X_train.shape[0]} imóveis")
print(f"Teste: {X_test.shape[0]} imóveis")
print()

lr_model = LinearRegression()
lr_model.fit(X_train, y_train)

y_pred = lr_model.predict(X_test)
r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmse_linear = np.sqrt(mean_squared_error(y_test, y_pred))

print(f"R² (Coeficiente de Determinação): {r2:.4f}")
print(f"Erro Médio Absoluto (MAE): {mae:.2f} €")
print(f"RMSE do Modelo Linear Global: {rmse_linear:.2f} €")
```

Anexo 8 – Criação do Modelo de Regressão Linear por Localização:

```
resultados_distritos = []

distritos = df_model['Location'].unique()

for distrito in distritos:
    df_d = df_model[df_model['Location'] == distrito]

    if len(df_d) > 50:
        X_d = df_d[['Area', 'Type']]
        y_d = df_d['Price']

        X_train_d, X_test_d, y_train_d, y_test_d = train_test_split(X_d, y_d, test_size=0.2, random_state=42)

        model_d = LinearRegression().fit(X_train_d, y_train_d)
        r2_d = model_d.score(X_test_d, y_test_d)
        mae_d = mean_absolute_error(y_test_d, model_d.predict(X_test_d))

        resultados_distritos.append({'Distrito': distrito, 'R2': r2_d, 'MAE': mae_d, 'Amostra': len(df_d)})


df_resultados = pd.DataFrame(resultados_distritos).sort_values(by='R2', ascending=False)
print(df_resultados)
```

Anexo 9 – Criação da Árvore de Decisão:

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.model_selection import train_test_split, GridSearchCV

df = pd.read_csv('dataset_merged.csv')
X = pd.get_dummies(df[['Area', 'Type', 'Location', 'Property']], drop_first=True)
y = df['Price']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
parametros_para_testar = {'max_depth': [3, 5, 7, 10, 12, 15, 20]}
print("A procurar a profundidade ideal... (Isto pode demorar alguns segundos)")
grid = GridSearchCV(DecisionTreeRegressor(random_state=42), parametros_para_testar, cv=5)
grid.fit(X_train, y_train)
melhor_profundidade = grid.best_params_['max_depth']
melhor_modelo = grid.best_estimator_
print(f"\n--- RESULTADOS DA OTIMIZAÇÃO ---")
print(f"A Profundidade Ideal encontrada foi: {melhor_profundidade}")
print(f"O R² deste modelo nos dados de teste é: {melhor_modelo.score(X_test, y_test):.3f}")
plt.figure(figsize=(24, 12))
plot_tree(melhor_modelo,
          feature_names=X.columns,
          filled=True,
          rounded=True,
          precision=0,
          fontsize=10,
          max_depth=3)
plt.title(f"Árvore Otimizada (Profundidade Real: {melhor_profundidade} - R²: {melhor_modelo.score(X_test, y_test):.2f})")
plt.savefig('arvore_decisao_otimizada.png', dpi=300, bbox_inches='tight')
```

Anexo 10 – Modelo da Árvore de Decisão



Referências:

Belfo, F. (2020). Data mining e business intelligence. Coimbra Business School | ISCAC.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.

Pereira, A. (2023). *Portuguese Real Estate Listings Dataset*. Kaggle. Disponível em: <https://www.kaggle.com/datasets/andpereira/portugal-real-estate-house-pricing>.

Pandas: McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference.

Scikit-learn: Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research.

Shiller, R. J. (2015). Irrational exuberance (3rd ed.). Princeton University Press.

XGBoost: Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference.